



Projekat I

AIS analitika nad HDFS + Spark

Mihajlo Madić 2119

Big Data Systems

Jun 2026, Niš

Dataset: Piraeus AIS

- Korišćen je javni dataset *The Piraeus AIS Dataset for Large-scale Maritime Data Analytics*, objavljen u okviru Zenodo repozitorijuma.
- Dataset sadrži AIS¹ zapise kreirane tokom aktivnosti brodova u okviru luke Pirej u Grčkoj.
- AIS zapisi opisuju kretanje brodova kroz attribute kao što su vreme slanja (`timestamp`), identifikator broda (`vessel_id`), geografska pozicija (`lon`, `lat`), brzina (`speed`), kurs² (`course`) i pravac (`heading`).
- Originalni dataset je dovoljno veliki za Big Data scenario; za ovaj prototip korišćen je kontrolisani podskup radi bržeg razvoja i lakšeg i kraćeg testiranja, i generisanja benchmark-ova.
- Izvor: <https://zenodo.org/records/5792100>

¹Automatic Identification System.

²Kurs (`course`) opisuje stvarni smer kretanja broda, dok pravac (`heading`) opisuje smer njegovog pramca.

Sistem:

- ❶ priprema podataka i upload na HDFS
- ❷ Spark aplikacija sa CLI upitima (`count`, `show`, `stats`)
- ❸ benchmark poređenje režima izvršavanja

Rezultati:

- reproducibilna infrastruktura kroz Docker Compose
- merenja performansi
- izveštaji sa rezultatima

Korišćen podskup:

- raw podaci: ~971.54 MiB (jul + decembar 2018 CSV)
- preprocesirani podaci: ~191.60 MiB (Parquet)

Relevantne HDFS putanje:

- /bds/proj1/raw
- /bds/proj1/processed/clean
- /bds/proj1/processed/quarantine
- /bds/proj1/processed/quality_report

3-slojni model:

- ① HDFS sloj: skladište (namenode, datanode)
- ② Spark sloj: obrada (spark-master, spark-worker-*)
- ③ App sloj: job submission i CLI (app)

Tok podataka

Raw CSV → HDFS /raw → preprocess job → HDFS /processed/*

- analytics CLI koristi count, show, stats
- svi benchmark testovi koriste isti izvor podataka (HDFS)

Servisi:

- namenode, datanode $\Rightarrow$ storage
- spark-master, spark-worker-1, spark-worker-2 $\Rightarrow$ compute
- app $\Rightarrow$ "bussiness" logic

Princip:

- isti HDFS izvor za oba benchmark moda
- app container submituje iste komande za `local[*]` i `spark://...`

Prva faza - upload podataka na HDFS

Checkpoint:

```
automation/phase1_hdfs_upload.sh
```

Ključne komande:

Komanda	Šta radi
<code>docker compose exec namenode</code>	Izvršava HDFS komande unutar namenode kontejnera, tj. tamo gde je dostupan Hadoop CLI.
<code>hdfs dfs -mkdir -p /bds/proj1/raw</code>	Kreira raw direktorijum u HDFS-u; opcija <code>-p</code> sprečava grešku ako putanja već postoji.
<code>hdfs dfs -put -f /input/.../jul2018.csv /bds/proj1/raw/jul2018.csv</code>	Uploaduje CSV za jul 2018. iz read-only input mount-a u HDFS raw zonu; <code>-f</code> omogućava overwrite.
<code>hdfs dfs -put -f /input/.../dec2018.csv /bds/proj1/raw/dec2018.csv</code>	Uploaduje CSV za decembar 2018. na istu HDFS lokaciju.
<code>hdfs dfs -count -h /bds/proj1/raw</code>	Verifikuje upload prikazom broja direktorijuma, fajlova i ukupne veličine u formatu čitljivom za čoveka.

Druga faza - preprocesiranje podataka (kroz Spark job)

Checkpoint:

```
automation/phase2_preprocessing.sh
```

Job:

```
docker compose exec app /spark/bin/spark-submit \  
  --master spark://spark-master:7077 \  
  /workspace/scripts/preprocess_ais_hdfs.py \  
  --input 'hdfs://namenode:9000/bds/proj1/raw/*.csv' \  
  --output-base hdfs://namenode:9000/bds/proj1/processed
```


Preprocessing logika

Ključne transformacije:

```
missing_required = timestamp/vessel_id/lon/lat missing  
invalid_geo      = lon/lat out of range  
invalid_speed    = speed < 0  
invalid_heading  = heading not in [0, 360]  
invalid_course   = course not in [0, 360]
```

```
clean      <- no hard_fail  
quarantine <- hard_fail rows
```

```
clean:      parquet partitioned by year, month  
quarantine: parquet partitioned by reason  
quality_report: summary + reason_counts
```

Komande:

- count
- show
- stats (min/max/avg/stddev + count)

Primeri:

```
ais_analytics.py count --year 2018 --month 12
```

```
ais_analytics.py show --year 2018 --month 7 --min-speed 15 \  
--sort-by timestamp --sort-desc --limit 20
```

```
ais_analytics.py stats --year 2018 --group-by month --metrics speed
```

Pravila za fer poređenje:

- isti dataset: `/processed/clean`
- ista komanda
- režimi: `--master local[*]` i `--master spark://spark-master:7077`

Kampanja (jedan kompletan benchmark):

- 5 iteracija
- svaka iteracija: 1 izvršenje po modu (klaster/standalone) + zaseban izveštaj
- zatim finalni agregat (5x2)

Benchmark alati i artefakti

Runner:

```
python3 scripts/benchmark_ais_analytics.py \  
  --benchmark-name <name> \  
  --modes both \  
  --repeats 1 \  
  --query-override "count ... | show ... | stats ..."
```

Aggregator:

```
python3 scripts/aggregate_benchmark_runs.py \  
  --runs-dir runs/campaign_<id>/runs \  
  --output-root runs/campaign_<id>/reports
```

Checkpoint:

```
automation/phase5_full_benchmarks.sh
```

Šta radi:

- ① podiže storage + compute + app sloj
- ② puni HDFS i izvršava preprocessing
- ③ pokreće 4 benchmark kampanje
- ④ za svaku kampanju pravi 5 iteracionih reporta + 1 finalni agregat

Struktura rezultata

```
runs/campaign_<id>/
  runs/
    standalone/<timestamp>/
      meta.json
      results.json
      summary.json
      run_report.md
    cluster/<timestamp>/
      ...
  reports/
    <timestamp>/aggregate.md
    <timestamp>/aggregate.csv
    <timestamp>/aggregate.json
```

meta.json čuva raw i processed size snapshot.

Rezultati 1GB: Stats (speed)

Kampanja: campaign_20260226T101745Z_stats_speed

```
stats --year 2018 --group-by month --metrics speed \  
  --order-by month --limit 12
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	11.049	10.350	11.781
cluster	5	15.444	15.023	16.202

Rezultati 1GB: Stats (heading, course)

Kampanja: campaign_20260226T102011Z_stats_heading_course

```
stats --year 2018 --group-by month --metrics heading,course \  
  --order-by month --limit 12
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	11.132	10.760	11.825
cluster	5	16.069	15.484	16.734

Kampanja: campaign_20260226T102241Z_count

count --year 2018 --month 12

mode	n	mean [s]	min [s]	max [s]
standalone	5	9.486	9.465	9.508
cluster	5	14.065	13.657	14.188

Kampanja: campaign_20260226T102453Z_show

```
show --year 2018 --month 7 --min-speed 15 \  
    --sort-by timestamp --sort-desc --limit 20
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	10.490	10.445	10.513
cluster	5	14.309	14.167	14.697

Poređenje: 1GB benchmark

Cluster/standalone odnos za **manji** skup:

benchmark	standalone mean [s]	cluster mean [s]	ratio	delta [s]
stats speed	11.049	15.444	1.397x	+4.395
stats heading, course	11.132	16.069	1.443x	+4.937
count dec2018	9.486	14.065	1.483x	+4.579
show fast jul2018	10.490	14.309	1.364x	+3.819

Raw: 971.54 MiB, processed parquet: 191.60 MiB, clean rows: 8.30M

Rezultati 5GB: Stats (speed)

Kampanja: campaign_20260627T140125Z_5gb_stats_speed

```
stats --year 2018 --group-by month --metrics speed \  
  --order-by month --limit 12
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	12.882	12.379	13.497
cluster	5	17.692	17.021	18.185

Rezultati 5GB: Stats (heading, course)

Kampanja: campaign_20260627T140416Z_5gb_stats_heading_course

```
stats --year 2018 --group-by month --metrics heading,course \  
  --order-by month --limit 12
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	14.551	14.493	14.612
cluster	5	19.803	19.196	20.193

Rezultati 5GB: Count

Kampanja: campaign_20260627T140724Z_5gb_count

count --year 2018 --month 12

mode	n	mean [s]	min [s]	max [s]
standalone	5	11.010	10.967	11.047
cluster	5	15.795	15.666	16.215

Kampanja: campaign_20260627T140955Z_5gb_show

```
show --year 2018 --month 7 --min-speed 15 \  
    --sort-by timestamp --sort-desc --limit 20
```

mode	n	mean [s]	min [s]	max [s]
standalone	5	12.035	12.004	12.052
cluster	5	16.529	16.153	16.815

Rezultati: ~5GB benchmark

- Ulazni skup podataka je proširen dodatnim podskupovima grupisanim po mesecima.
- Cluster/standalone odnos za **veći** skup:

benchmark	standalone mean [s]	cluster mean [s]	ratio	delta [s]
stats speed	12.882	17.692	1.373x	+4.810
stats heading, course	14.551	19.803	1.361x	+5.252
count dec2018	11.010	15.795	1.435x	+4.785
show fast jul2018	12.035	16.529	1.373x	+4.494

Raw: 4.60 GiB, processed parquet: 812.68 MiB, clean rows: 40.29M

Skaliranje: 1GB prema 5GB

Poređenje srednjih vremena izvršavanja:

benchmark	1GB standalone	1GB cluster	5GB standalone	5GB cluster
stats speed	11.049	15.444	12.882	17.692
stats heading, course	11.132	16.069	14.551	19.803
count dec2018	9.486	14.065	11.010	15.795
show fast jul2018	10.490	14.309	12.035	16.529

Odnos veličina:

- raw: 971.54 MiB prema 4.60 GiB ($\sim 4.85x$)
- parquet: 191.60 MiB prema 812.68 MiB ($\sim 4.24x$)

Zaključci za manji obim (~1GB raw, ~192MB parquet):

- `local[*]` je brži u svim testovima.
- Upiti su kratki i latency-bound: skeniranje parquet-a, filtriranje i male agregacije.
- Cluster dodaje overhead: scheduling, driver/executor komunikaciju i serijalizaciju (Docker mreža).
- `count` i `show` su stabilniji zbog jednostavnosti; `stats` ima više varijanse zbog grupisanja i agregacija.

Rezultat je očekivan u odnosu na manji benchmark:

- Cluster je i dalje sporiji, a delta ostaje oko +4.5s do +5.3s.
- Odnos vremena se nije bitno promenio: 1.36x do 1.44x.
- Veći ulaz povećava vreme, ~linearno sa veličinom ulaznog skupa (parquet format).
- Fiksni Spark overhead još uvek dominira nad dobitcima zbog paralelizacije.

Zašto cluster nema bolje performanse?

Infrastruktura:

- Cluster radi na istom fizičkom hostu, sa ograničenim brojem worker-a.
- HDFS ima jedan datanode, pa nema prave distribuirane data locality prednosti.
- Worker-i i Spark master komuniciraju preko Docker mreže.
- Testirani upiti nisu dovoljno teški da amortizuju cenu distribuiranog izvršavanja.

Najveći efekat skaliranja se video u preprocessing fazi: čitanje 4.60 GiB raw CSV-a, validacija 40.29M redova i upis u storage sistem (HDFS).

Ograničenja eksperimenta:

- dva obima podataka, ali jedan host i jedan datanode
- meren je latency pojedinačnih batch upita, ne throughput pod konkurentnim opterećenjem
- workload koristi relativno jednostavne filtre, sortiranje i agregacije

Za očekivanu cluster prednost može se testirati:

- više datanode/worker čvorova
- veći procesirani skup i teže operacije
- Promena Spark cluster konfiguracije: executor memorija i broj executor-a

Ponavljjanje eksperimenta – referenca

```
# HDFS + preprocess baseline
```

```
bash automation/phase2_preprocessing.sh
```

```
# jedna benchmark kampanja
```

```
python3 scripts/benchmark_ais_analytics.py ...
```

```
python3 scripts/aggregate_benchmark_runs.py ...
```

```
# 5GB benchmark sa cleanup-om
```

```
bash automation/phase5_5gb_benchmarks.sh
```

Sve kampanje i izveštaji su timestamped i append-only.

Pitanja?

Kraj